

Autor:

Rafael Henrique Martello

Endereço: Rua General Lima e Silva, 152 – Apt. 1101 Bloco B – Centro Histórico,
Porto Alegre – RS, Brasil. CEP: 90050-100

Telefone: +55 (49) 9 8830 – 5836

Correio eletrônico: rafam6@unochapeco.edu.br

Título:

**Desenvolvimento de um software para
Classificação de Doenças na Soja utilizando de
Técnicas de Inteligência Artificial para análise em
Tempo Real**

Resumo

A soja (*Glycine max*) é considerada uma das culturas de maior importância econômica mundial. Nas últimas décadas vários esforços foram desenvolvidos para evitar perdas de safras devido a doenças. Identificar uma doença corretamente de forma precoce, pode evitar perdas na produção e gastos elevados com defensivos agrícolas. O presente trabalho teve como objetivo a obtenção de um software para futura aplicação em drones e *smartphones*, visando o controle e a identificação de doenças em plantações de soja, utilizando uma base de imagens construída com 5659 imagens de 9 classes distintas, e avaliada com quatro modelos de redes convolucionais, sendo usados como modelo base a rede ResNet50, DenseNet201, VGG19 e EfficientNetB7 visando a obtenção do melhor modelo de classificação que poderá auxiliar no diagnóstico de doenças foliares. As imagens foram pré-processadas e convertidas para um formato 256 x 256 pixels divididas em treino e teste em uma proporção 80:20 e treinadas e avaliadas por 50 épocas. Os modelos apresentaram resultados superiores a 87%, com o melhor resultado provindo da rede DenseNet201 com 93,19% de precisão de classificação dos dados de teste. O modelo foi convertido em um software para sistema operacional Android e testado em imagens digitais.

Abstract

Soy (*Glycine max*) is considered one of the most economically important crops in the world. In the last decades, several efforts have been made to avoid crop losses due to diseases. Identifying a disease correctly at an early stage can prevent losses in production and high expenses with pesticides. This study aimed to obtain a software for future use in drones and smartphones, for control and identification of diseases in soybean fields, using a constructed base of images with 5659 images in 9 different classes, and evaluated with four models of convolutional networks, ResNet50, DenseNet201, VGG19, and EfficientNetB7 were used as the base model for the networks, aiming to obtain the best classification model that can assist in the diagnosis of leaf diseases. The images were pre-processed and converted to a 256 x 256 pixel format divided into training and testing in an 80:20 ratio and trained and evaluated for 50 epochs. The models showed results greater than 87%, with the best result coming from the DenseNet201 network with 93.19% accuracy of classification of the test data. The model was converted into software for the Android operational system and tested on digital images.

INTRODUÇÃO

O desenvolvimento tecnológico possibilitou sociedade humana produzir alimentos para atender a demanda de mais de 7 bilhões de pessoas. No entanto, a segurança alimentar continua ameaçada por uma série de fatores, incluindo as mudanças climáticas. Plantas são afetadas por uma variedade de doenças e pragas, que envolvem complexas relações entre a planta, o patógeno e o vetor. Muitas vezes essas doenças estão relacionadas a mudanças na umidade, temperatura e nível de precipitação, levando a impactos na produção e consequentemente, impactos para a vida humana. O problema das doenças em plantas afeta o mundo todo também relacionado a segurança alimentar (FUENTES, et al. 2017; MOHANTY, HUGHES & SALATHÉ, 2016).

A soja (*Glycine max*) é considerada uma das culturas de maior importância econômica mundial, com ampla adaptação aos climas tropicais e subtropicais, tem grande importância para a vida humana, principalmente por possibilitar a produção de grandes quantidades de proteínas para a alimentação animal e óleo para consumo humano (BEZERRA, et al., 2015; CARVALHO, et al. 2010; FEDERIZZI, 2005). Segundo dados da USDA (2020), a soja apresenta uma área de plantio de 126,87 milhões de hectares distribuídos em todo o globo, sendo 61,62 milhões apenas na América do Sul, compreendendo uma produção mundial de 370,4 milhões de toneladas e regional para os países da América do Sul de 199,75 milhões.

Segundo dados do IBGE (2017) obtidos no Censo Agropecuário de 2017, o Brasil apresenta uma média de 130 hectares por produtor, totalizando 236.245 produtores, o que representa uma média baixa quando visualizando os mais de 500 mil hectares do maior produtor do país. O monitoramento de territórios desse tamanho é uma tarefa gigantesca, portanto, os agricultores tem procurado respostas em novas tecnologias, dessa forma a agricultura de precisão traz a combinação de dados de sensor e imagens com análise de dados em tempo real para melhorar a produtividade da fazenda por meio do mapeamento da variabilidade espacial no campo (SYLVESTER, 2018).

Devido à grande importância da soja para o mercado internacional, cuidados devem ser tomados referentes as várias doenças causadas por fungos, bactérias, vírus e nematoides. O diagnóstico precoce é de extrema importância

para o manejo de agrotóxicos, podendo reduzir o impacto ambiental e perdas econômicas (TETILA, et al. 2017). Segundo Dallagnol et al. (2006), doenças foliares causadas por fungos podem comprometer 20% do rendimento de grãos de uma cultura, podendo chegar a 75% no caso de doenças como a ferrugem asiática.

Nas últimas décadas vários esforços foram desenvolvidos para evitar perdas de safras devido a doenças. O controle de pestes usualmente consiste em tomada de decisões baseadas no nível de infestação e o estágio de desenvolvimento da planta, essas informações devem ser obtidas regularmente e usualmente são feitas de forma visual. No entanto, em grandes áreas cultivadas essas inspeções tornam-se difíceis (TETILA, et al. 2017; MOHANTY, HUGHES & SALATHÉ, 2016).

Desta forma, muitas vezes realiza-se a aplicação de pesticidas de forma inadequada, seja através de aplicações preventivas ou em fases de crescimento incorretas, levando a um grande desequilíbrio nas lavouras e acarretando problemas como a eliminação de inimigos naturais. Assim, pragas normalmente consideradas sem importância econômica poderão causar grandes perdas na produção, necessitando de controle. Tudo isso levando a um maior custo de produção e consequências drásticas de poluição ambiental (SOSA-GÓMEZ et al., 2001; 2003; 2009),

Identificar uma doença corretamente quando ela aparece pela primeira vez é uma etapa crucial para o tratamento eficiente da doença, podendo evitar perdas na produção e gastos elevados com defensivos agrícolas. Como alternativa para os métodos de amostragem manual, temos métodos de *machine learning* associados a agricultura de precisão, permitindo a classificação e reconhecimento de objetos, tornando a aplicação de insumos agrícolas nos locais corretos e nas quantidades requeridas uma realidade (TETILA, et al. 2017; MOHANTY, HUGHES & SALATHÉ, 2016).

Tendo em vista o crescente campo de *machine learning* e a elevada importância da soja, o presente trabalho teve como objetivo a obtenção de um software para futura aplicação em drones e *smartphones* de controle e identificação de doenças em plantações de soja, utilizando uma base de imagens

desenvolvida com nove classes e avaliada com quatro modelos de redes convolucionais.

TRABALHOS RELACIONADOS

Para obter diagnósticos precisos, vários pesquisadores realizaram a identificação automatizada de doenças com base no processamento digital de imagens como Barbedo (2013), visão computacional como Khairnar e Dagade (2014) e reconhecimento de padrões como Phadikar e Sil (2008). Algoritmos para classificação de doenças foram utilizados em trabalhos como de Mohanty, Hughes e Salathé (2016) que aplicou um processo de transferência de aprendizado. O sistema proposto pelo autor classificou 26 doenças de 14 diferentes espécies de plantas usando uma base de dados de 54.306 imagens com uma precisão de 99,35%. Rangarajan, Purushothaman e Ramesh (2018) também desenvolveram trabalho semelhante voltado para classificação de doenças em Tomate utilizando como modelos de rede AlexNet e VGG16 obtendo resultados de 97,29% e 97,49% respectivamente.

Kaur, Pandey e Goel (2018) também trabalharam na classificação de doenças em soja com uma base de dados para identificação de três doenças aplicando em modelos de *Support Vector Machine* (SVM) e obtendo resultados de 88% na classificação. Shrivastava, Singh e Hooda (2015) objetivaram a identificação de doenças usando uma base de 347 imagens e classificadores *Support Vector Machine* (SVM), *K-Nearest Neighbor* (KNN) e *Probabilistic Neural Network* (PNN) obtendo resultados próximos a 95%.

Jadhav, Udupi e Patil (2020) trabalharam na classificação de doenças de soja utilizando 5 classes distintas com uma base de fotos de 630 a 730 fotos utilizando as redes AlexNet e GoogleNet obtendo resultados de 98,75% e 96,25% respectivamente. Além disso, essas técnicas avançadas são usadas para analisar várias frutas e espécies de culturas, como uvas no trabalho de Kim, Burks e Qin (2009) e trigo como por Goodfellow, Bengio e Courville (2016).

Diferente da maior parte dos trabalhos que focam apenas no desenvolvimento do modelo, o presente trabalho realizou a implementação do modelo gerando um software que pode ser aplicado em qualquer aparelho Android.

JUSTIFICATIVA

A soja é uma das culturas de maior importância econômica no mundo. A produtividade dessa cultura está diretamente associada a interação da planta com o ambiente e seu manejo, o custo de seu cultivo está atrelado ao uso de fertilizantes e pesticidas, sendo os dois principais componentes a compor o valor (TETILA, et al. 2017).

O manejo adequado e aplicação precisa de defensivos é uma alternativa interessante para redução de custos e consequentemente aumento de produção, visto que doenças causadas por fungos, bactérias, vírus e nematoides acarretam na perda de produtividade, assim como a aplicação em excesso dos produtos.

Consequentemente a identificação e controle de forma precisa torna-se atrativa. Nesse contexto, a agricultura inteligente, conceito emergente que tem por princípio tornar o manejo de culturas mais eficiente com a ajuda de algoritmos, vem ganhando destaque. Utilizando o aprendizado de máquina juntamente com tecnologias de ciência de dados, torna-se possível criar novas oportunidades para desvendar, quantificar e compreender processos agrícolas.

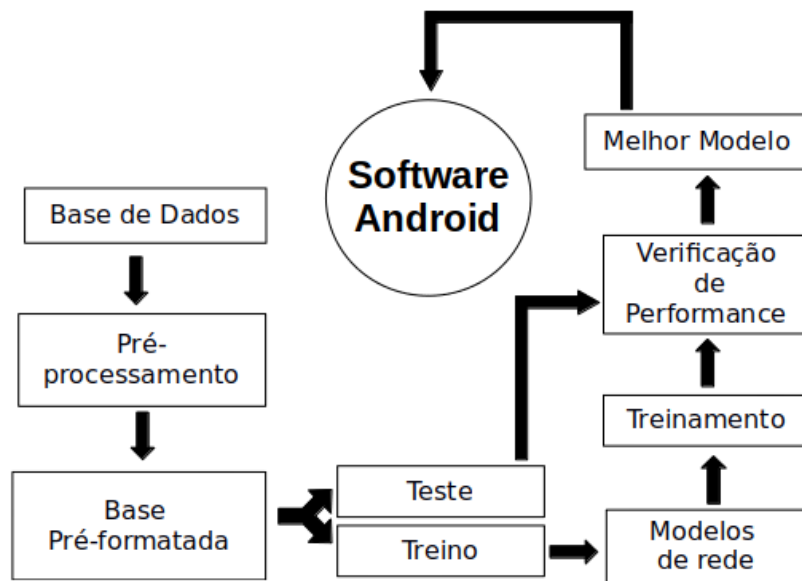
Tendo em vista o crescente campo de *machine learning* e a elevada importância da soja, o presente trabalho teve como objetivo a obtenção de um software para futura aplicação em drones e *smartphones* de controle e identificação de doenças em plantações de soja.

METODOLOGIA

Descrição do desenho experimental:

O trabalho tem como objetivo identificar nove classes de doenças que afetam a soja usando *Deep Learning*. Uma visão geral do sistema é apresentada na Figura 01. A seguir, será descrito em detalhes cada componente da abordagem proposta.

Figura 01. Desenho experimental.



Todos os códigos foram executados através do Google Collaboratory utilizando o ambiente de GPU executado através da Nvidia Tesla K80. Os modelos foram desenvolvidos em Python 3.6 utilizando como base a biblioteca Tensorflow 2.3.0.

Descrição da Base de Dados:

A base de dados foi constituída utilizando imagens presentes na Base de Imagens de Sintomas de Doenças de Plantas (PDDB) da Embrapa referenciada em Barbedo, Koenigkan e Santos (2016), imagens retiradas de *New Plant Diseases Dataset* (Kaggle) referenciada em Bhattarai (2018) e complementada com imagens obtidas por algoritmo google-images-download referenciado em Vasa (2019), compondo um total de 5659 imagens divididas em 9 classes conforme a Tabela 01. As imagens foram coletadas com diferentes dimensões e fundos variados, visando uma melhor robustez da rede e consequentemente uma classificação mais adequada.


Tabela 01. Descrição da Base de dados.

Classe:	Nº Amostras
Folha saudável	898
Mancha alvo (<i>Corynespora cassiicola</i>)	612
Mancha parda (<i>Septoria glycines</i>)	629
Oídio (<i>Microsphaera diffusa</i>)	639
Ferrugem (<i>Phakopsora pachyrhizi</i> e <i>P. meibomiae</i>)	604
Míldio (<i>Peronospora manshurica</i>)	581
Crestamento bacteriano (<i>Pseudomonas savastanoi</i> pv. <i>Glycinea</i>)	589
Fitotoxidade de cobre	650
Vírus Mosaico (SMV)	457

Pré-Processamento da base de dados:


Como primeira etapa de pré-processamento todas as imagens foram convertidas para dimensões e extensão padrão. para dimensões de 256 x 256 pixels e um formato jpg, correspondendo ao aspecto da Figura 02.

Figura 02. Imagens representativas da base de dados.



Sistemas de Deep learning tem mostrado excelente desempenho em relação a outros algoritmos, mas muitas vezes necessitam de pré-processamento para evitar *overfitting*. Para isso utiliza-se o *data augmentation*, aumentando o número de dados e realizando transformações de geometria (redimensionamento, corte, rotação, inversão horizontal) e transformações de intensidade (contraste, aumento de brilho, cor e ruído). Para o presente estudo realizou-se um *RandomFlip* horizontal seguido de *RandomRotations* obtendo a Figura 03

Figura 03. Imagens representativas do Pré-processamento (*Data Augmentation*).



Por fim realizou-se uma normalização na base deixando os valores das camadas na faixa de 0 a 1.

Segmentação da base de dados:

Existem vários atributos que descrevem propriedades físicas das imagens, que dependem principalmente da cor, gradiente, textura e forma. Para classificação de imagens, algoritmos de *machine learning* usam as imagens descritas para identificar e classificar de acordo com padrões visuais. Foram empregados modelos supervisionados com conjuntos de treino e teste divididos de forma aleatória na proporção 80:20 compreendendo 4528 imagens para treino e 1131 imagens para o teste.

Modelos de rede e Treinamento


Foram selecionados quatro modelos para comparação de classificação, treinados durante 50 épocas com tamanho de lote (*batch*) de 8 imagens pré-inicializados com pesos 'imagenet'.

VGG 19

Redes neurais convolucionais VGG tem seis estruturas principais, sendo cada uma composta por múltiplas camadas convolucionais conectadas, o número de camadas é geralmente concentrado em 16-19 camadas. VGG-19 é usada como um modelo de pré-processamento, ligado a uma rede neural subsequente (XIAO, et al. 2020).

O modelo é representado por Xiao, et al. (2020) conforme a Figura 04:

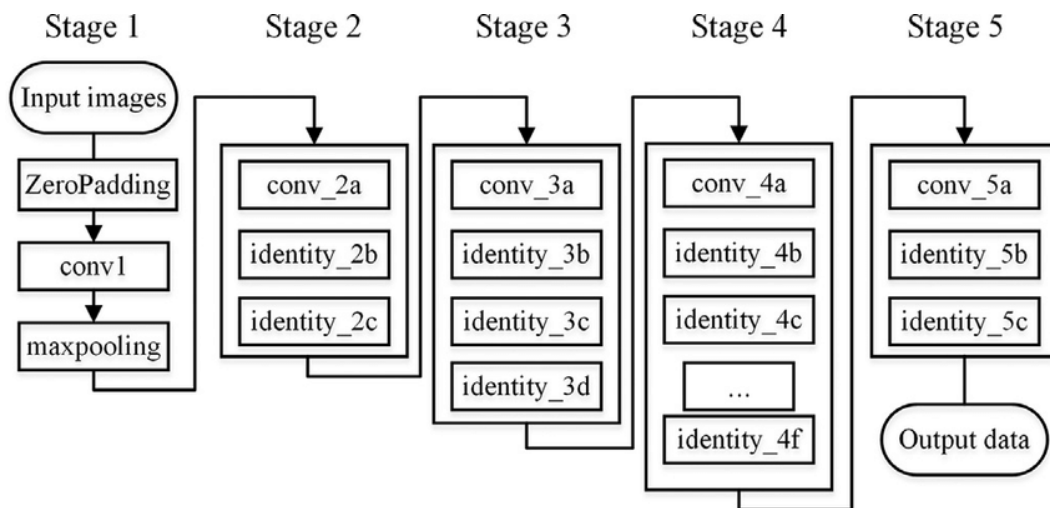
Figura 04. Estrutura do modelo VGG-19 (XIAO, et al. 2020).



ResNet 50

ResNet, abreviação de Residual Networks, é uma rede neural clássica usada como backbone para muitas tarefas de visão computacional. Este modelo foi o vencedor do desafio ImageNet em 2015. O modelo ResNet-50 consiste em 5 estágios, cada um com uma convolução e bloco de identidade. Cada bloco de convolução possui 3 camadas de convolução e cada bloco de identidade também possui 3 camadas de convolução, o modelo total compreende 50 camadas, daí surge seu nome.


Figura 05. Estrutura do modelo ResNet 50 (SHI, et al. 2019).



DenseNet201

No modelo DenseNet, cada camada obtém entradas adicionais de todas as camadas anteriores e passa seus próprios mapas de recursos para todas as camadas subsequentes. A concatenação é usada. Cada camada está recebendo um “conhecimento coletivo” de todas as camadas anteriores. A rede DenseNet-201 apresenta 201 camadas em sua composição, mas apresenta menor número de parâmetros pois realiza a concatenação de resultados.

Figura 06. Estrutura do modelo DenseNet (YILMAZ; KÖSE & DEMİR 2019).

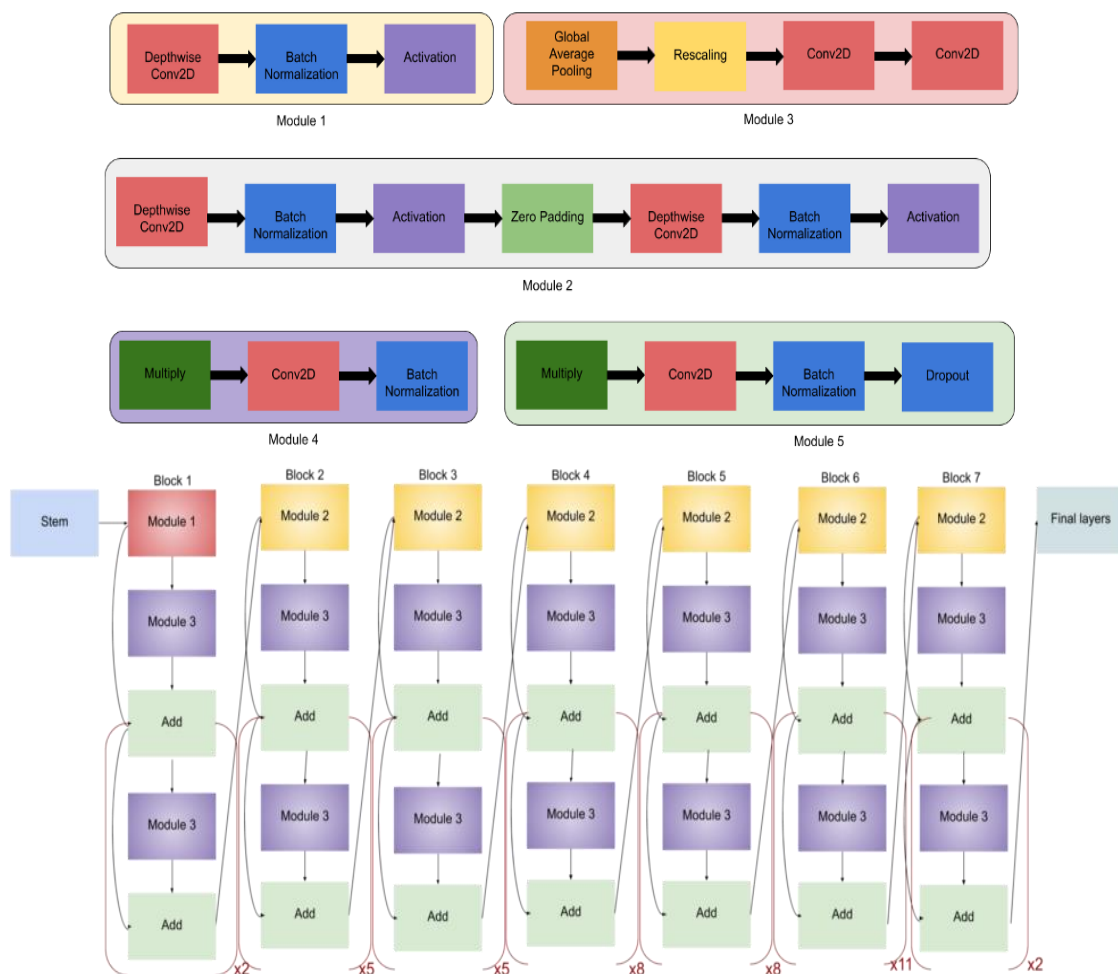


EfficientNetB7

Para solucionar o problema relacionado ao tamanho (largura, profundidade e resolução) dos modelos foram criadas as redes EfficientNet. Considerando que o aumento das características ajuda a rede inicialmente, mas por fim acaba prejudicando a performance, na EfficientNet, os parâmetros são dimensionados de uma maneira fundamentada, gradualmente tudo é aumentado. O que leva a diferença entre os modelos B0 a B7 são os sub-blocos (ligações entre os módulos) que aumentam conforme se altera o nome do modelo. O modelo EfficientNetB7 é composto por 5 módulos distribuídos em três grupos de submódulos totalizando um total de 813 camadas.

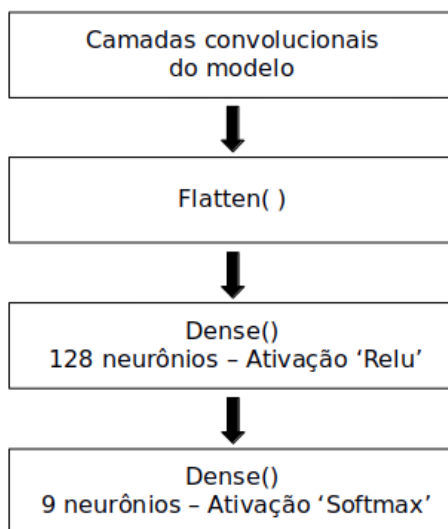
A estrutura dos módulos e da EfficientNetB7 estão demonstrados na Figura 07.

Figura 07. Estrutura do modelo EfficientNetB7 (AGARWAL, 2020).



A saída das camadas convolucionais foi ligada a três camadas conforme a Figura 08, possibilitando a etapa da classificação.

Figura 08. Estrutura do modelo.



Dados adicionais dos modelos estão disponíveis na Tabela 02, apresentando o número de variáveis treináveis e não treináveis de cada modelo após a compilação.

Tabela 02. Modelos utilizados.

Modelo	Variáveis	
	Treináveis	Não treináveis
VGG 19	24.219.977	0
ResNet 50	40.313.097	53.120
DenseNet201	33.822.857	229.056
EfficientNetB7	84.759.769	310.727

Verificação de Performance

Para a verificação da performance dos modelos foram traçados gráficos de precisão (*accuracy*) e de perda (*loss*) nas etapas de treino e teste, realizou-se uma análise de tempo de treinamento verificando quanto tempo levou cada época de treino, pegando um valor médio para as 50 épocas, assim podendo verificar o modelo com melhor comportamento. Como segunda etapa de verificação de performance foram desenvolvidas previsões sobre os dados de teste que foram validadas através de uma matriz de confusão.

Implementação do Modelo

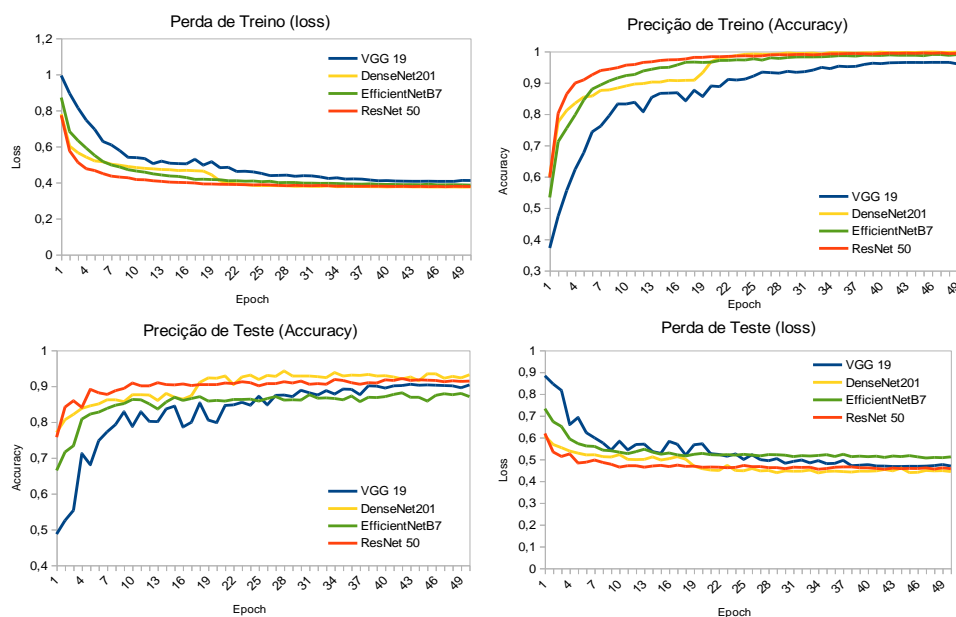
O modelo com melhores resultados de performance foi tratado com a biblioteca Tensorflow, salvando o modelo e as labels em arquivos (tflite e txt) e processando através do programa Android Studio 4.0.1.

O modelo de rede foi convertido em um aplicativo Android e testado através de um Android Virtual Device (AVD) com versão android 10.0. O software foi desenvolvido baseado em exemplos disponíveis no repositório do Tensorflow disponíveis na referência Tensorflow (2018).

RESULTADOS

Através do treinamento em 50 épocas, foram obtidos os gráficos da Figura 09 que compreendendo dados de perda (*loss*) e precisão (*accuracy*) para os dados de treinamento e teste.

Figura 09. Gráficos de teste e treinamento:



Através dos gráficos podemos visualizar que os modelos com melhores resultados foram o ResNet50 e o DenseNet201, com representatividade elevada tanto de treino quanto de teste, chegando no patamar mais elevado de forma mais rápida (menor número de épocas). Autores como Mukti e Biswas (2019) e Too et al. (2018) mostraram a eficiência de modelos semelhantes para classificação de doenças atingindo resultados excelentes.

Partindo dos dados obtidos nos gráficos e fazendo uma análise de tempo médio de treinamento temos a Tabela 03.

Tabela 03. Valores finais dos modelos:

Modelo	Perda de Treino	Precisão de Treino	Perda de Teste	Precisão de Teste	Tempo por época [s]
VGG 19	0,4114	0,9605	0,4694	0,9036	131
ResNet 50	0,3778	0,9947	0,4572	0,9142	73
DenseNet201	0,3752	0,9971	0,4441	0,9319	112
EfficientNetB7	0,3859	0,9907	0,5114	0,8709	540

Através da tabela três podemos ver que o modelo com melhor resultado na precisão de teste foi o DenseNet201 com 93,19% e um tempo médio de 112s por época, seguido do modelo ResNet50 com 91,43% e 73s. Dados parecidos foram obtidos por Mukti e Biswas (2019), que apresentou como melhor modelo o DenseNet com 100% de precisão e o Resnet com 99,99%, seguidos pelo VGG19. Too et al. (2018) também apresentou dados melhores para o modelo ResNet50 com 98,42% de precisão e para o modelo VGG19 97,95%.

Outros autores como Jadhav, Udupi e Patil (2020), Mohanty, Hughes e Salathé (2016) e Kashyap e Shrivastava (2020) também mostraram a capacidade de redes neurais para auxiliar agricultores no combate de pragas e doenças.

Partindo do modelo DenseNet201 que obteve os melhores resultados de treinamento e teste, foram realizadas predições sobre a base de treinamento visando obtenção de dados de classificação e com isso a possibilidade de gerar uma matriz de confusão (Figura 10) com dados preditos e reais.

Figura 10. Matriz de confusão para o modelo DenseNet201:

Crestamento bacteriano	105	0	0	0	0	1	0	1	4
Mancha parda	6	88	0	4	0	1	0	0	12
Fito Cobre	1	4	134	0	0	0	0	0	0
Míldio	1	0	0	119	0	0	1	0	0
Saudável	0	1	0	0	176	2	0	0	0
Vírus mosaico	0	1	0	1	0	83	0	0	5
Oídio	0	0	0	0	0	0	135	0	0
Ferrugem	0	0	1	0	0	0	1	109	1
Mancha alva	1	11	6	1	1	5	3	3	102
	Crestamento bacteriano	Mancha parda	Fito Cobre	Míldio	Saudável	Vírus mosaico	Oídio	Ferrugem	Mancha alva

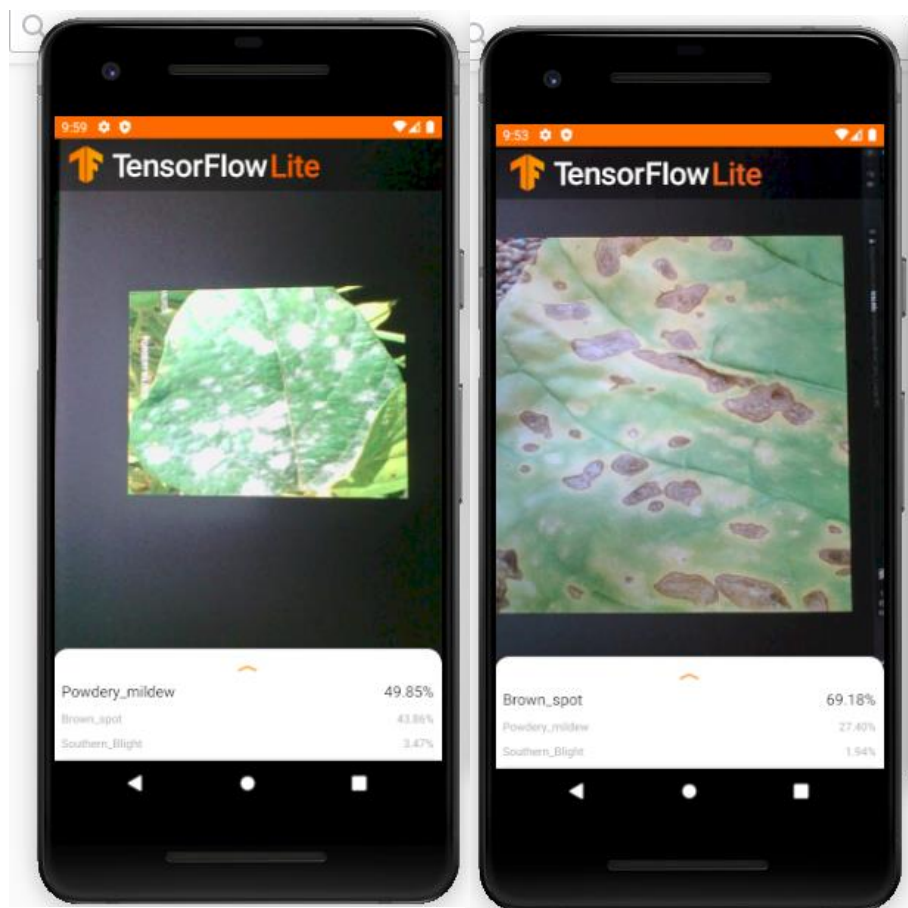
Matrizes de confusão são usualmente utilizadas para demonstrar de forma visual a qualidade de predição dos modelos de redes neurais. Com isso torna-se possível verificar a qualidade e assertividade do modelo.

Vale lembrar que os valores falso positivos podem ser reduzidos se implementarmos uma avaliação em área, estipulando um diâmetro de detecção de contaminação de doenças e avaliando os possíveis erros de detecção dentro dessa área, delimitando um número mínimo de detecções para se considerar uma doença como realmente presente, com isso podemos aprimorar ainda mais o algoritmo.

Usando o algoritmo foi calculado o tempo de classificação para as 1131 imagens de teste em 6,13s, sendo um tempo médio por foto de 5,421ms. Esse valor demonstra que o algoritmo tem capacidade para detecção em tempo real sendo uma ideia para implementação na agricultura de precisão através da utilização de drones.

O modelo treinado foi convertido no software conforme o que é demonstrado na Figura 11 e testado com algumas imagens disponíveis na internet para verificar a assertividade.

Figura 11. Demonstração do classificador rodando em um aparelho Android .



Com o software desenvolvido torna-se possível aplicar em qualquer dispositivo Android para identificação de doenças na soja, podendo ser uma alternativa para identificação preliminar ligada a *smartphones* ou mesmo de forma embarcada aplicado em drones para agricultura de precisão, possibilitando o controle de áreas muito maiores de plantação e aplicação correta de defensivos agrícolas’.

CONCLUSÃO

No presente trabalho foram avaliados quatro modelos de aprendizagem profunda para classificação de doenças foliares em soja. Os 4 apresentaram valores adequados com precisões superiores a 87%. O DenseNet201 foi o modelo mais adequado para classificação da base de fotos criada. Dessa forma mostrando que a base de dados teve qualidade para geração de um modelo de redes neurais adequado para classificação de doenças na soja.

Mesmo com bons resultados de classificação os valores de perda (*loss*) ainda estão um pouco altos, sendo necessário refinar a base de dados para obter valores menores e mais adequados. Como parte dos possíveis trabalhos futuros, gostaríamos de refinar a base de dados para englobar mais doenças e ter um maior número de fotos por classe, permitindo resultados ainda melhores, com o sistema já desenvolvido em um software torna-se interessante a realização de testes em campo, visto que os testes realizados foram com imagens digitais. Para a realização desses testes seria necessário a inclusão da rede um drone de vistoria e o refino da base de dados utilizando fotos coletas pelo mesmo. O software também poderia ser testado em menor escala através do uso em *smartphones* considerando que ele já está no formato para o sistema operacional Android.

AGRADECIMENTOS

Agradecemos ao Centro Nacional de Desenvolvimento Científico e Tecnológico (CNPq), à Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) e ao Laboratório GIMSCOP da Universidade Federal do Rio Grande do Sul.

REFERÊNCIAS

- AGARWAL, V. Complete Architectural Details of all EfficientNet Models. 2020 Disponível em: <https://towardsdatascience.com/complete-architectural-details-of-all-efficientnet-models-5fd5b736142> Acesso: 07 de Setembro de 2020.
- BARBEDO, J. G. A. Digital image processing techniques for detecting, quantifying and classifying plant diseases. SpringerPlus, vol. 2, no.1, p. 660–672, 2013.
- BARBEDO, J. G. A.; KOENIGKAN, L. V.; SANTOS, T. T. Identifying multiple plant diseases using digital image processing. Biosystems Engineering, v. 147, p. 104-116, 2016.
- BEZERRA, A. R. G.; et al. Importância Econômica. In: SEDIYAMA, T.; SILVA, F.; BORÉM, A. (ed.). Soja: do plantio à colheita. Viçosa: UFV, 2015, p. 9-26.
- BHATTARAI, S. New Plant Diseases Dataset. Disponível em: <https://www.kaggle.com/vipooooool/new-plant-diseases-dataset/> Acesso: 07 de Setembro de 2020.
- CARVALHO, E. R. et al . Desempenho de cultivares de soja [Glycine max (L.) Merrill] em cultivo de verão no sul de Minas Gerais. Ciênc. agrotec., Lavras , vol. 34, no. 4, p. 892-899, 2010.
- DALLAGNOL, L. J.; NAVARINI, L.; UGALDE, M. G.; BALARDIN, S.; CATELLAM, R. Utilização de Acibenzolar-S-Methyl para Controle de Doenças Foliares da Soja. Summa Phytopathol., Botucatu, vol. 32, no. 3, p. 255-259, 2006.
- FEDERIZZI, L. C. A soja como fator de competitividade no Mercosul: histórico, produção e perspectivas futuras. Primeiras jornadas de economia regional comparada, vol. 1, 2005.
- FUENTES, A.; YOON, S.; KIM, S. C.; PARK, D. S. A robust deep-learning-based detector for real-time tomato plant diseases and pests recognition,” Sensors, vol. 17, no. 9, p. 2022, 2017. Referências
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep learning. MIT Press, p. 1–783, 2016.
- IBGE. Censo Agropecuário. 2017. Disponível em: https://censos.ibge.gov.br/agro/2017/templates/censo_agro/resultadosagro/agricultura.html Acesso: 07 de Setembro de 2020.

JADHAV, S. B., UDUPI, V. R., & PATIL, S. B. Identification of plant diseases using convolutional neural networks. *International Journal of Information Technology*, 2020.

KASHYAP, Y., SHRIVASTAVA, S. S. Assessment of Soybean Leaf foliar Diseases using CNN & Weka tool. 2nd International Conference on Data, Engineering and Applications (IDEA), 2020

KAUR, S.; PANDEY, S.; GOEL, S. Semi-automatic leaf disease detection and classification system for soybean culture. *IET Image Proc*, vol. 12, no. 6, p. 1038–1048, 2018.

KHAIRNAR, K.; DAGADE, R. Disease detection and diagnosis on plant using image processing—a review. *Int J Comput Appl*, vol. 108, no.13, p. 36–39, 2014.

KIM, D. G.; BURKS, T. F.; QIN, J.; BULANON, D. M. Classification of grapefruit peel diseases using color texture feature analysis. *Int J Agric Biol Eng*, vol. 2, no. 3, p.41–50, 2009.

MOHANTY, S. P., HUGHES, D. P., SALATHÉ, M. Using deep learning for image-based plant disease detection. *V. 7. Front Plant Sci*. 2016.

MUKTI, I. Z.; BISWAS, D. Transfer Learning Based Plant Diseases Detection Using ResNet50. 4th International Conference on Electrical Information and Communication Technology (EICT), 2019.

PHADIKAR, S.; SIL, J. Rice disease identification using pattern recognition techniques. In: *Proceedings of the IEEE International Conference on Computer and Information Technology (ICCIT)*, Khulna, Bangladesh, p. 420–423, 2008.

SHI, Z.; LIU, M.; CAO, Q.; REN, H.; LUO, T. A data augmentation method based on cycle-consistent adversarial networks for fluorescence encoded microsphere image analysis. *Signal Processing*, vol. 161, p. 195-202, 2019.

SHRIVASTAVA, S.; SINGH, S. K.; HOODA, D. S. Soybean plant foliar disease detection using image retrieval approaches. *Multimedia Tools Appl*, vol. 76, no. 24, p. 26647–26674, 2016.

SOSA-GOMEZ, D.R.; CORSO, I.C.; MORALES, L. Insecticide resistance to endosulfan, monocrotophos and metamidophos in the neotropical brown stink bug, *Euschistus heros* (F.). *Neotropical Entomology*, vol. 30, p. 317-320, 2001.

SOSA-GÓMEZ, D.R.; DELPIN, K.E.; MOSCARDI, F.; NOZAKI, M.H. The impact of fungicides on *Nomuraea rileyi* (Farlow) Samson epizootics and on populations

of *Anticarsia gemmatalis* Hubner (Lepidoptera: Noctuidae), on soybean. *Neotropical Entomology*, Londrina, vol. 32, p.287-291, 2003.

SOSA-GÓMEZ, D.R.; SILVA, J.J.; LOPES, I.O.N.; CORSO, I.C.; ALMEIDA, A.M.R.; MORAES, G.C.P.; BAUR, M.E. Susceptibility of *Euschistus heros* (Heteroptera: Pentatomidae) adults to insecticides used in Brazilian soybeans. *Journal Economic of Entomology*, vol. 102, p.1209pro-1216, 2009.

SYLVESTER, G. E-AGRICULTURE IN ACTION: DRONES FOR AGRICULTURE. Food and Agriculture Organization of the United Nations and International Telecommunication Union. ISBN 978-92-5-130246-0s. Bangkok, 2018.

TENSORFLOW. Exemplos, 2018.

Disponível em: <https://github.com/tensorflow/examples> Acesso: 07 de Setembro de 2020.

TETILA, E. C.; MACHADO, B. B.; BELETE, N. A. D. S.; GUIMARÃES, D. A.; PISTORI, H. "Identification of soybean foliar diseases using unmanned aerial vehicle images," *IEEE Geoscience and Remote Sensing Letters*, vol. 14, no. 12, p. 2190–2194, 2017.

TOO, E. C.; YUJIAN, L., NJUKI, S.; YINGCHUN, L. A comparative study of fine-tuning deep learning models for plant disease identification. *Computers and Electronics in Agriculture*, 2018.

USDA, World Agricultural Production. United States Department of Agriculture (USDA). 2020

VASA, H. google-images-download. MIT.

Disponível em: <https://github.com/hardikvasa/google-images-download> Acesso: 07 de Setembro de 2020.

XIAO, J.; WANG, J.; CAO, S.; LI, B. Application of a Novel and Improved VGG-19 Network in the Detection of Workers Wearing Masks. *J. Phys.: Conf. Ser. Vol. 1518*, 2020.

YILMAZ, F.; KÖSE, O.; DEMİR, A. Comparison of Two Different Deep Learning Architectures on Breast Cancer 2019 Medical Technologies Congress 2019.